Báo cáo xây dựng & kiểm định bộ skill viết tài liệu sản phẩm

Phiên bản	Ngày	Người thực hiện	Trạng thái
v2.2	2026-11-03	Claude (skill-creator) cho Le Nhat	Sẵn sàng dùng thử nội bộ

Mục lục

1. Bộ skill
2. Phương pháp kiểm định
3. Kết quả
4. Lỗi đã phát hiện nhờ kiểm định & đã sửa
5. Hạn chế & rủi ro (phản biện)
6. Việc nên làm tiếp

Tóm tắt: Bộ 4 skill giúp agent viết tài liệu sản phẩm/kỹ thuật chặt chẽ, không bịa, trình bày chuyên nghiệp (MD → PDF/DOCX/XLSX). Kiểm định bằng 7 phương pháp qua 2 vòng lặp. So với Claude không có skill: tỉ lệ đạt assertion 92,5% vs 72,0% (10 case); blind A/B thắng 8/8 case nội dung (vòng 1) và 1/2 case định dạng (vòng 2 — case thua đã sửa, chưa chấm lại). Điểm yếu còn lại: tài liệu vẫn dài hơn mức lý tưởng với input rất ngắn, và chi phí thời gian cao hơn baseline khoảng 2–2,5 lần.

1. Bộ skill

Skill	Dùng khi	Công cụ đi kèm
`product-spec-writer`	BRD, PRD, SRS, user story + AC Gherkin, use case, metric definition (DA)	templates, `lint_doc.py`, `render_doc.py`
`codebase-doc-writer`	README, API reference, architecture (C4/arc42), ADR, runbook từ source code	`scan_repo.py` (inventory file:line)
`diagram-to-doc`	Ảnh flowchart/BPMN/sequence/ERD/state/wireframe → đặc tả, data dictionary	`zoom_tiles.py`, `check_diagram.py` (kiểm inventory + Mermaid round-trip)
`doc-clarity-review`	Review/viết lại tài liệu có sẵn: mơ hồ, mâu thuẫn, không test được	rubric 17 mã lỗi, `lint_doc.py`

Dùng chung trong cả 4 skill (nguồn duy nhất `_shared/`, đồng bộ bằng `build.sh`):

- `writing-standards.md`: modal RFC 2119, EARS, bảng từ mơ hồ VI/EN, quy tắc ⚑ CẦN XÁC NHẬN, độ dài tương xứng.
- `visual-style.md`: quy tắc trình bày và quy trình visual QA.
- `lint_doc.py`: linter.
- `render_doc.py`: xuất PDF A4 / PDF mobile / DOCX / XLSX.

Nguyên tắc thiết kế chính:

- Tách hai pha *thu thập fact có nguồn* và *diễn đạt*.

- Không bao giờ tự quyết thay stakeholder: mâu thuẫn và giá trị thiếu được đánh dấu ⚑ CẦN XÁC NHẬN và đưa vào Open Questions.
- Đề xuất của agent tách riêng khỏi đặc tả.

2. Phương pháp kiểm định

#	Phương pháp	Đo cái gì	Kết quả
1	Structural validation (`quick_validate`, package)	Frontmatter, cấu trúc skill	4/4 hợp lệ
2	Unit test các script (48 test)	Linter (true/false positive VI+EN), scan_repo (ground truth 5 route / 6 env var), check_diagram, render_doc (end-to-end, mobile, sheet naming)	48/48 pass
3	Eval có skill vs không skill (10 case, LLM grader + script)	Assertion khách quan theo từng case	Xem §3
4	Blind A/B comparator	Judge không biết bên nào là skill	Xem §3
5	Ground-truth fidelity	Diagram sinh từ DOT có đáp án: edge recall, column accuracy, planted-issue recall	Flowchart 16/16 cạnh; ERD 25/25 cột; review 13/13 lỗi cài sẵn (v2)
6	Routing eval bằng `claude -p` thật	Cả 4 skill cài cùng lúc, 26 query × 2 lượt (gồm 6 near-miss)	52/52 (100%); vẫn 52/52 khi cài thêm 3 skill đối thủ (`docs`, `docx`, `technical-writer`)
7	Visual QA	Ảnh trang PDF/DOCX được judge xem trực tiếp; check font nhúng, chữ có dấu, Mermaid lộ mã, cỡ chữ hiệu dụng	Xem §3.3

3. Kết quả

3.1 Vòng 1 (v1, 8 case nội dung)

- Assertion: có skill **97,5%** vs không skill 85,5%.
- Blind A/B: có skill thắng **8/8**, điểm TB 9,1 vs 8,3.
- Chi phí: +85% thời gian, +30% token.
- Judge chê bản có skill độn nội dung (mục RFC 2119, glossary từ hiển nhiên, câu hỏi mở lặp lại).

3.2 Vòng 2 (v2, assertion siết lại + 2 case định dạng)

So sánh	Assertion	Blind A/B
v2 vs không skill (10 case)	**92,5%** vs 72,0%	Chỉ chạy blind trên 2 case định dạng: thắng PRD→Word, thua ERD→mobile (§3.3). 8 case nội dung: xem v1 vs baseline ở §3.1
v2 vs v1 (8 case chung)	**94,9%** vs 91,0%	v2 thắng 6/8; v1 thắng sát 2/8 (architecture 9,3–9,0; ERD 9,0–8,7)

- Độ dài tài liệu v2 giảm **32%** so với v1, token giảm 7%.
- Thời gian tăng, chủ yếu do v2 chạy kiểm chứng code thật nhiều hơn.

Khác biệt thật giữa có skill và không skill:

- Bản không skill hay **bịa giá trị** vào requirement/AC: enum trạng thái, ngưỡng 10.000, p95 ≤ 2s, chọn 5 phút OTP.
- Bản không skill **trộn đề xuất vào đặc tả**.
- Bản không skill lint bẩn hơn.
- Bản có skill phát hiện nhiều lỗi thật trong fixture hơn: redis-py 8.x làm worker crash, `make worker` không chạy do thiếu `.PHONY`, `.env` bị pydantic từ chối biến lạ.

3.3 Thẩm mỹ & định dạng

Case	Lần chạy	Kết quả blind	Ghi chú
PRD → Word	v2	thắng 9,0–6,5	marker vàng, bảng full ngang; thiếu số trang
PRD → Word	v2.1	thắng 8,5–6,3	
PRD → Word	v2.2	—	đã thêm footer "Trang x/y", Title/Heading chuẩn Word, ID không gãy, 3.267 từ (từ 4.173)
ERD → Excel + PDF điện thoại	v2	**thua** 7,7–9,0	xuất A4, chưa có chế độ mobile
ERD → Excel + PDF điện thoại	v2.1	**thua** 6,0–9,0	chữ thực tế 5–6pt
ERD → Excel + PDF điện thoại	v2.2	—	đã sửa: cỡ chữ đo được 16,9pt; thêm check tự động cảnh báo khi chữ < 7,5pt

Bản v2.2 của case ERD/mobile **chưa được chấm lại bằng blind A/B**. Đây là việc cần làm đầu tiên ở vòng sau.

4. Lỗi đã phát hiện nhờ kiểm định & đã sửa

Linter

- Đếm `AC-001.1` / `AC-001.2` là ID trùng.
- Bắt nhầm "không được lưu" (modal cấm) là câu bị động.
- Bắt nhầm heading "User stories" là lệch thuật ngữ.
- Bảng ánh xạ/truy vết bị báo trùng ID.
- Từ "mềm" (nhiều, đầy đủ) bị xếp mức high.

Renderer

- Mermaid ERD làm méo `DECIMAL(12,2)`; ERD hiển thị "UK" thay cho "UQ".
- Tên sheet Excel mất dấu `_`; bảng metadata thành sheet rác.
- Mục lục DOCX tiếng Anh, trống; DOCX không có số trang.
- PDF mobile bị thu nhỏ cả trang.

Hướng dẫn trong skill

- Agent tự chế rule ON DELETE.
- Agent dựng AC trên giá trị tự chọn.

- Cột "Hạn" độn trong bảng câu hỏi mở.
- Bảng câu hỏi mở bị lặp lại ở phụ lục.
- Thiếu bảng 3 biến thể retention.
- "Nguyên nhân gốc là..." khẳng định khi chưa có dữ liệu.

Bản thân bộ eval

- Một assertion sai sự thật (khuyên đặt SMTP_HOST vào `.env`).
- Một assertion thiên vị cách làm của skill (bắt buộc mỗi bảng một sheet).
- Nhiều assertion không phân biệt được các config → đã thay bằng assertion sắc hơn.

5. Hạn chế & rủi ro (phản biện)

1. **Assertion chưa đủ:**
    - Ở case README, baseline đạt 10/10 assertion dù hướng dẫn của nó làm worker crash.
    - Ở case metric, cả 3 cấu hình đều 7/9.
    - Kết luận: phải đọc kết hợp với blind A/B và đọc output thật, không chỉ nhìn % pass.
2. **Mẫu nhỏ:** 1 run cho mỗi cấu hình mỗi case, chưa có variance. Chênh 1–2 điểm ở judge là trong biên nhiễu.
3. **Judge cùng họ model với executor** (Claude chấm Claude). Có thể có thiên vị phong cách; nên thêm human blind review với BA/PO thật.
4. **Linter có tính vòng tròn:** skill dặn chạy chính linter dùng để chấm. Chỉ coi là chỉ số tuân thủ quy trình.
5. **Độ dài:** input 9 dòng chat vẫn ra PRD ~3.300 từ, mục tiêu là ≤ 2.500.
6. **Chi phí:** thời gian chạy ~2–2,5 lần baseline. Đổi lại là kiểm chứng thật và ít bịa hơn.
7. **Phụ thuộc môi trường:** PDF/DOCX cần pandoc, Chrome, mmdc. Thiếu thì skill vẫn giao `.md` và báo rõ định dạng nào chưa xuất được.
8. **Sự cố quy trình:** 2 run gọi nhầm Artifact; một lần đã publish rồi xóa ngay. Prompt test sau đó đã cấm hẳn.

6. Việc nên làm tiếp

- Chạy lại blind A/B case ERD-mobile và PRD-docx với v2.2, mỗi cấu hình 3 run để đo variance.
- Human blind review 5–10 tài liệu với BA/PO trong team.
- Thêm fixture khó hơn:
    - ảnh chụp whiteboard nghiêng, mờ;
    - BPMN có gateway song song;
    - repo Node/Java;
    - tài liệu tiếng Anh.
- Chạy `claude plugin eval` trên các thư mục `evals/` (đã đúng format) để tích hợp CI.